SmartTrafficFlow AI

Predicción inteligente de congestión en Madrid

1. Título del Proyecto e Integrantes 1
2. Resumen Ejecutivo 2
3. Descripción Funcional del Sistema 3
3.1. Flujo General de Operación 3
3.2. Casos de Uso Principales 3
3.3. Capacidades y Limitaciones (Alcance Funcional) 3
4. Alcance Definitivo (IN / OUT) 3
4.1. Elementos IN (Compromisos Obligatorios) 4
4.2. Alcance Opcional (Mejoras Sujetas a Disponibilidad) 4
4.3. Elementos OUT (Excluidos Explícitamente) 4
5. Arquitectura del Sistema (Alto Nivel) 4
5.1. Diagrama de Arquitectura de Alto Nivel 5
5.2. Descripción de Componentes Técnicos 5
5.3. Flujo de Información y Orquestación 5
6. Tecnologías Seleccionadas 5
6.1. Núcleo de Desarrollo y Frameworks 6
6.2. Ecosistema de Datos y Machine Learning 6
- Visualización (Plotly / Matplotlib): Integradas en el dashboard para ofrecer gráficos interactivos que permitan al usuario explorar las predicciones de forma dinámica. 6
- 6.3. Infraestructura y Herramientas Auxiliares 6
7. Modelo de Datos 7
7.1. Entidades Principales 7
7.2. Diccionario de Datos y Relaciones 7
7.3. Ingeniería de Variables (Feature Dictionary) 8
7.4. Integridad del Modelo 8
8. Datos 8
8.1. Fuente, Naturaleza y Licencia 8
8.2. Características del Dataset (Volumetría) 9
8.3. Calidad y Riesgos Asociados 9
8.4. Uso Operativo 9
9. Ética, Legalidad y Accesibilidad 9
9. Ética, Legalidad y Accesibilidad 10
9.1. Privacidad y Cumplimiento Legal (GDPR) 10
9.2. Gestión de Sesgos y Medidas de Mitigación 10
9.3. Accesibilidad y Usabilidad 10
9.4. Uso Ético del Sistema 11

10. Backlog Inicial (Historias de Usuario) 11
11. Plan de Trabajo (6 Semanas) 12
11.1. Cronograma y Reparto de Responsabilidades 13
11.2. Hitos Principales y Dependencias 13
11.3. Gestión de Riesgos Iniciales 13
12. Estrategia de Desarrollo 14
12.1. Flujo de Trabajo (Git Flow) 14
12.2. Protocolo de Validación y Testing 14
3. Testing de Integración: Pruebas de flujo completo para asegurar que el Dashboard en Streamlit visualiza correctamente los outputs del motor de ML. 14
13. Matriz de Riesgos Técnicos Actualizada 14
14. Estructura del Repositorio 15
14.1. Organización de Directorios 15

1. Título del Proyecto e Integrantes

Nombre del Proyecto: SmartTrafficFlow AI: Sistema Predictivo de Congestión de Tráfico en Madrid mediante Big Data y Machine Learning.

Descripción del Objetivo: El proyecto consiste en el desarrollo de una solución tecnológica avanzada capaz de anticipar niveles de congestión de tráfico en la ciudad de Madrid con una antelación de 30 a 60 minutos. Mediante el uso de modelos de *Machine Learning* y procesamiento de grandes volúmenes de datos, el sistema proporciona valor estratégico a través de un dashboard interactivo diseñado para la toma de decisiones y la optimización de la movilidad urbana.

Equipo de Trabajo y Roles:

Para garantizar la excelencia técnica y operativa, el equipo se ha estructurado bajo roles especializados que cubren el ciclo de vida completo del proyecto de IA:

- **Jokin Mel — Project Manager & ML Engineer * Rol:** Liderazgo estratégico y supervisión técnica.
    - **Responsabilidades:** Coordinación general, definición de objetivos, implementación de modelos *baseline* y validación de métricas de rendimiento.
- **Donovan Alexis Yaguana — Data Engineer & BI Developer * Rol:** Gestión de activos de datos y visualización de negocio.
    - **Responsabilidades:** Ingesta y limpieza de datos, *feature engineering* y desarrollo de componentes visuales en Streamlit.
- **Francisco Peiró — Machine Learning Engineer & MLOps * Rol:** Optimización de modelos y aseguramiento de la calidad.
    - **Responsabilidades:** Entrenamiento avanzado de algoritmos, validación de resultados, control de versiones y garantía de reproducibilidad del sistema.
- **Marcos Cobos — BI Developer & Platform Engineer * Rol:** Desarrollo de plataforma e integración de sistemas.
    - **Responsabilidades:** Arquitectura del dashboard web, integración de modelos en producción y preparación del entorno de despliegue y KPIs.

2. Resumen Ejecutivo

SmartTrafficFlow AI aborda la problemática crítica de la congestión urbana en Madrid, un fenómeno que afecta la movilidad, incrementa la contaminación y penaliza la eficiencia logística. A diferencia de las herramientas actuales, mayoritariamente descriptivas (estado actual), nuestra solución propone un enfoque **predictivo** basado en tecnologías de **Big Data y Machine Learning**.

El sistema integra y procesa datos históricos de sensores viales, variables meteorológicas y patrones temporales para anticipar los niveles de congestión con un horizonte de **30 a 60 minutos**. Mediante el entrenamiento de algoritmos avanzados, la plataforma transforma datos complejos en información accionable, visualizada a través de un **dashboard interactivo** e intuitivo.

El valor diferencial de este proyecto reside en su capacidad de proporcionar una herramienta de **toma de decisiones proactiva**, permitiendo una planificación de desplazamientos optimizada y sentando las bases para una gestión urbana más inteligente, sostenible y eficiente en la capital.

3. Descripción Funcional del Sistema

SmartTrafficFlow AI es una solución web diseñada para la estimación predictiva de la congestión vial en Madrid. El sistema transforma datos brutos de sensores históricos y variables externas en conocimiento anticipado, permitiendo visualizar el estado del tráfico con un horizonte de **30 a 60 minutos**.

3.1. Flujo General de Operación

El sistema opera mediante un proceso lineal de cuatro etapas:

1. **Ingesta y Preprocesamiento:** Carga del *Madrid Traffic Dataset* y aplicación de técnicas de *Feature Engineering* (limpieza, transformación y unión con datos meteorológicos/temporales).
2. **Inferencia:** El modelo de Machine Learning procesa los datos transformados para generar predicciones de intensidad y ocupación.
3. **Persistencia:** Las predicciones se estructuran y almacenan para su consumo eficiente.
4. **Explotación:** El usuario accede al dashboard web para visualizar los resultados de forma gráfica e interactiva.

3.2. Casos de Uso Principales

- **Consulta de Predicción Localizada:** El usuario selecciona un sensor o zona específica para anticipar el nivel de congestión y optimizar su ruta o tiempo de salida.
- **Análisis de Patrones Históricos:** Identificación de tendencias basadas en variables temporales (hora punta, días festivos) y condiciones climáticas.
- **Monitorización Global:** Supervisión del estado general de la red vial de Madrid para obtener una visión macroscópica del tráfico urbano.

3.3. Capacidades y Limitaciones (Alcance Funcional)

El sistema PUEDE	**El sistema NO PUEDE**
Predecir niveles de congestión a corto plazo (30-60 min).	Procesar datos en tiempo real (streaming directo).
Visualizar tendencias históricas y estacionales.	Actuar como sistema de navegación GPS (rutas).
Permitir consultas filtradas por ubicación o sensor.	Gestionar accidentes o imprevistos no registrados.
Integrar variables climáticas en el pronóstico.	Ofrecer una aplicación móvil nativa (App Store/Play Store).

4. Alcance Definitivo (IN / OUT)

Este apartado delimita los compromisos técnicos y funcionales del proyecto **SmartTrafficFlow AI**, estableciendo las bases del Producto Mínimo Viable (MVP) y los límites de ejecución para esta fase inicial.

4.1. Elementos IN (Compromisos Obligatorios)

Se garantiza la implementación de los siguientes bloques funcionales:

- **Gestión de Datos:** Ingestión y tratamiento del *Madrid Traffic Dataset* (formato CSV), limpieza de valores nulos, normalización y aplicación de *feature engineering* avanzado sobre variables temporales y meteorológicas.
- **Modelado Predictivo:** Desarrollo, entrenamiento y validación de modelos de aprendizaje supervisado (Random Forest y/o XGBoost) para la predicción de tráfico a corto plazo (t+30 y t+60 min).
- **Evaluación Técnica:** Validación del rendimiento mediante métricas de error industrial: MAE (*Mean Absolute Error*), RMSE (*Root Mean Square Error*) y R^2.
- **Interfaz de Usuario:** Dashboard interactivo desplegado en **Streamlit** que permita la visualización de series temporales, comparativas histórico-predicción y análisis de tendencias.

4.2. Alcance Opcional (Mejoras Sujetas a Disponibilidad)

- **Segmentación Espacial:** Implementación de técnicas de *Clustering* para la predicción por zonas geográficas de Madrid.
- **Optimización de Modelos:** Ajuste fino de hiperparámetros (*Hyperparameter Tuning*) y pruebas con arquitecturas de redes neuronales recurrentes (LSTM/GRU).
- **Despliegue Cloud:** Publicación de la solución en entornos productivos como Streamlit Cloud o Hugging Face Spaces.
- **Exposición de Datos:** Creación de una API básica para la consulta programática de predicciones.

4.3. Elementos OUT (Excluidos Explícitamente)

Para asegurar el éxito del proyecto en los plazos establecidos, quedan fuera del alcance:

- **Sincronización en Tiempo Real:** No se integrarán APIs con streaming de datos en vivo (DGT/Ayuntamiento) en esta fase.
- **Plataformas Móviles:** El sistema será exclusivamente web (*Responsive*), sin aplicación nativa (iOS/Android).
- **Funcionalidades de Navegación:** El sistema no es un GPS; no calcula rutas ni tiempos de llegada entre puntos A y B.
- **Seguridad Avanzada:** No se implementarán sistemas de autenticación, logueo de usuarios o gestión de perfiles.

5. Arquitectura del Sistema (Alto Nivel)

La arquitectura de **SmartTrafficFlow AI** se basa en un diseño modular y desacoplado, lo que facilita el mantenimiento y la escalabilidad de cada componente. El sistema se organiza en cinco capas principales que cubren desde la ingesta de datos brutos hasta la entrega de valor al usuario final.

5.1. Diagrama de Arquitectura de Alto Nivel

(Aquí se debe insertar el diagrama que incluya: Pipeline → Storage → ML Engine → Backend → Frontend)

5.2. Descripción de Componentes Técnicos

1. **Pipeline de Datos (ETL):** Desarrollado en **Python (Pandas/NumPy)**. Es el encargado de la limpieza de datos, la gestión de valores nulos y el *Feature Engineering* (transformación de variables temporales y climáticas). Este componente garantiza la integridad y calidad del dato que consume el modelo.
2. **Capa de Almacenamiento (Data Store):** En esta fase inicial, se utiliza una estructura de **archivos CSV optimizados** derivados del *Madrid Traffic Dataset*. Actúa como repositorio central para los datos históricos, las variables de entrenamiento y los resultados de validación.
3. **Motor de Machine Learning (Servicios ML):** Implementado con **Scikit-learn y XGBoost**. Este módulo gestiona el ciclo de vida del modelo: desde el entrenamiento y la optimización de hiperparámetros hasta la generación de inferencias (predicciones) a corto plazo.
4. **Backend (Lógica de Negocio):** Desarrollado en **Python**. Actúa como el orquestador del sistema, coordinando las peticiones del frontend, consultando la capa de almacenamiento y activando el motor de predicción cuando es requerido.
5. **Frontend & Dashboard:** Interfaz interactiva desarrollada en **Streamlit**. Proporciona un entorno visual de alta fidelidad donde el usuario puede segmentar la información por sensores, consultar tendencias históricas y visualizar las predicciones mediante gráficas dinámicas.

5.3. Flujo de Información y Orquestación

El sistema sigue una secuencia lógica de datos (*Data-Driven*):

- **Fase de Preparación:** El **Pipeline** transforma los datos brutos que el **Servicio ML** utiliza para generar el modelo entrenado.
- **Fase de Ejecución:** El **Frontend** lanza una petición que el **Backend** procesa. Este último recupera los datos necesarios, solicita la predicción al **Modelo** y devuelve una respuesta estructurada que el **Dashboard** renderiza en tiempo real para el usuario.
-

6. Tecnologías Seleccionadas

El *stack* tecnológico de **SmartTrafficFlow AI** ha sido seleccionado bajo criterios de eficiencia, soporte académico y capacidad de integración. Se ha priorizado un entorno unificado en Python para minimizar la fricción entre el desarrollo del modelo y su despliegue en el dashboard.

6.1. Núcleo de Desarrollo y Frameworks

- **Lenguaje: Python 3.x:** Elegido como eje vertebrador del sistema por ser el estándar industrial en Data Science. Su sintaxis clara y su vasto ecosistema de librerías permiten una transición fluida desde el análisis exploratorio hasta la producción.
- **Framework de Interfaz: Streamlit:** Se ha seleccionado sobre alternativas como Flask o Django por su capacidad para generar dashboards de alta fidelidad directamente en Python. Esto acelera el ciclo de desarrollo del MVP sin requerir una arquitectura compleja de frontend (JS/CSS).

6.2. Ecosistema de Datos y Machine Learning

El procesamiento de datos y la inteligencia del sistema se apoyan en librerías de alto rendimiento:

- **Manipulación de Datos (Pandas & NumPy):** Herramientas esenciales para el tratamiento de series temporales y operaciones vectorizadas, garantizando un procesamiento eficiente de los sensores de Madrid.
- **Modelado Predictivo (Scikit-learn & XGBoost):** Se utilizará **Scikit-learn** para la creación de modelos *baseline* y preprocesamiento, y **XGBoost** como modelo avanzado por su probada eficacia y precisión en datos tabulares y problemas de regresión de tráfico.
- **Visualización (Plotly / Matplotlib):** Integradas en el dashboard para ofrecer gráficos interactivos que permitan al usuario explorar las predicciones de forma dinámica.

6.3. Infraestructura y Herramientas Auxiliares

Categoría	Tecnología	Justificación Técnica
Persistencia	**CSV (Estructurado)**	Formato óptimo para la naturaleza estática del dataset actual; facilita la portabilidad y el acceso rápido mediante Pandas.
Control de Versiones	**Git & GitHub**	Garantiza la trazabilidad del código, la gestión de ramas (*Git Flow*) y la colaboración síncrona del equipo.
Entorno de Trabajo	**VS Code & Jupyter**	Combinación de un IDE robusto para el backend y cuadernos interactivos para la fase crítica de experimentación (EDA).

Categoría	Tecnología	Justificación Técnica
Gestión de Entorno	**Virtualenv (venv)**	Aislamiento de dependencias para evitar conflictos de versiones y asegurar la reproducibilidad del sistema.

7. Modelo de Datos

El sistema **SmartTrafficFlow AI** emplea un modelo de datos relacional optimizado para series temporales. La arquitectura de datos integra la información estática de la red vial con variables dinámicas de tráfico y meteorología, permitiendo una trazabilidad completa desde el dato bruto hasta la predicción final.

7.1. Entidades Principales

El modelo se estructura en torno a cuatro entidades clave conectadas mediante identificadores de sensor (`sensor_id`) y marcas de tiempo (`timestamp`):

1. **Sensor (Dimensión Estática):** Almacena la ubicación y características físicas de los dispositivos de medición (ID, coordenadas latitud/longitud, zona y descripción).
2. **Traffic_Data (Hechos de Tráfico):** Registra las métricas fundamentales recolectadas: intensidad (vehículos/hora), ocupación de la vía (%) y velocidad media.
3. **Weather_Data (Variables Externas):** Datos meteorológicos (temperatura, precipitación, humedad) que actúan como variables exógenas críticas para mejorar la precisión del modelo.
4. **Predictions (Resultados ML):** Almacena los *outputs* del modelo, incluyendo el valor predicho, el horizonte temporal y el algoritmo específico utilizado.

7.2. Diccionario de Datos y Relaciones

Entidad	Campos Clave (PK/FK)	Descripción Técnica
Sensor	`sensor_id` (PK)	Catálogo maestro de puntos de medición en Madrid.
Traffic_Data	`traffic_id` (PK), `sensor_id` (FK)	Histórico de mediciones vinculado a cada sensor (Relación 1:N).
Weather_Data	`weather_id` (PK)	Observaciones climáticas vinculadas por `timestamp` al tráfico.
Predictions	`prediction_id` (PK), `sensor_id` (FK)	Resultados de inferencia vinculados al sensor correspondiente.

7.3. Ingeniería de Variables (Feature Dictionary)

Para el entrenamiento del modelo, se han derivado variables adicionales de alto valor predictivo:

- **Variables Temporales:** Día de la semana, hora del día y flag de festivo (extraídas del `timestamp`).
- **Métricas de Tráfico:** Intensidad, ocupación y velocidad (normalizadas para el modelo).
- **Variables Climáticas:** Nivel de lluvia y temperatura, fundamentales para detectar variaciones anómalas en el flujo vehicular.

7.4. Integridad del Modelo

La consistencia de los datos se garantiza mediante el uso de:

- **Claves Primarias (PK):** Garantizan la unicidad de cada registro de tráfico y predicción.
- **Claves Foráneas (FK):** Mantienen la integridad referencial entre los sensores y sus mediciones.
- Alineación Temporal: Sincronización estricta de todas las fuentes de datos bajo un formato estándar ISO 8601.

8. Datos

El sistema **SmartTrafficFlow AI** se fundamenta en el análisis de datos masivos reales. La integridad de las predicciones depende directamente de la calidad y el volumen del dataset seleccionado, el cual proporciona un contexto histórico robusto sobre la movilidad en Madrid.

8.1. Fuente, Naturaleza y Licencia

- **Origen:** *Madrid Traffic Dataset (MTD)*, obtenido del repositorio público **Mendeley Data**. Es una fuente académica de referencia que recopila series temporales de la red vial de Madrid.
- **Naturaleza:** Se trabaja con **datos reales** capturados por estaciones de medida físicas. No se utilizan datos simulados ni sintéticos (*mocked*), lo que otorga al proyecto una validez científica y profesional superior.
- **Licencia:** Uso público bajo fines educativos y de investigación, cumpliendo con los requisitos de citación y uso no comercial del repositorio original.

8.2. Características del Dataset (Volumetría)

El sistema gestiona un volumen considerable de información estructurada:

- **Cobertura Espacial:** ~554 sensores distribuidos por toda la ciudad (el MVP se enfocará en un subconjunto crítico de ~300).
- **Alcance Temporal:** Registros continuos de entre 17 y 30 meses, permitiendo capturar estacionalidad (invierno/verano) y patrones anuales.
- **Frecuencia:** Mediciones registradas en intervalos de 5 a 15 minutos, sumando varios millones de registros y un tamaño en disco de hasta 2 GB.

8.3. Calidad y Riesgos Asociados

A pesar de la alta fidelidad de la fuente, se han identificado riesgos inherentes a los datos de sensores físicos, los cuales serán tratados en el **Pipeline de Datos**:

Riesgo Técnico	Impacto en el Modelo	Estrategia de Mitigación
Datos Faltantes	Vacíos en las series temporales por fallos de sensor.	Aplicación de técnicas de imputación (media móvil) o eliminación de registros incompletos.
Ruido y Outliers	Valores anómalos que distorsionan la precisión.	Filtrado estadístico y limpieza de valores extremos fuera de rango lógico.
Sesgo Temporal	Cambios en patrones (ej. obras en vía o pandemia).	Validación mediante *Time-Series Split* para asegurar la capacidad de generalización.
Heterogeneidad	Comportamientos distintos según la zona de Madrid.	Normalización de variables y posibilidad de entrenamiento segmentado por distritos.

8.4. Uso Operativo

Los datos se integran en el ciclo de vida de la IA para tres funciones críticas:

1. **Entrenamiento:** Ajuste de los parámetros del modelo ML para detectar patrones de congestión.
2. **Evaluación:** Uso de conjuntos de *test* para verificar la capacidad predictiva con datos nunca vistos.
3. **Visualización:** Representación de tendencias históricas en el dashboard para proporcionar contexto al usuario.

9. Ética, Legalidad y Accesibilidad

Para el **Punto 9 (Ética, Legalidad y Accesibilidad)**, el enfoque debe ser impecable. Los proyectos de IA actuales son evaluados con lupa en cuanto a responsabilidad y sesgos. He integrado las explicaciones legales detalladas con una estrategia de mitigación de sesgos muy sólida, utilizando un lenguaje que demuestra compromiso con la ética de datos.

9. Ética, Legalidad y Accesibilidad

El desarrollo de **SmartTrafficFlow AI** se rige por principios de responsabilidad y transparencia. Se ha diseñado un marco de cumplimiento que garantiza que el uso de la Inteligencia Artificial sea seguro, legal y equitativo.

9.1. Privacidad y Cumplimiento Legal (GDPR)

El sistema opera bajo el principio de **Privacidad por Diseño**:

- **Ausencia de PII (Personally Identifiable Information):** El proyecto utiliza exclusivamente métricas técnicas (intensidad, ocupación, velocidad) y variables ambientales. No se procesan matrículas, imágenes de conductores, nombres ni ninguna otra información que permita identificar a un individuo.
- **Alineación con el GDPR:** Al utilizar datos públicos, agregados y estrictamente anónimos procedentes de fuentes institucionales, el sistema cumple con el Reglamento General de Protección de Datos. No se realiza perfilado de usuarios ni se toman decisiones automatizadas que afecten a la esfera privada de las personas.

9.2. Gestión de Sesgos y Medidas de Mitigación

Reconocemos que todo sistema basado en datos reales puede heredar sesgos. Por ello, hemos establecido estrategias proactivas:

Riesgo de Sesgo	Descripción Técnica	Estrategia de Mitigación
Sesgo Geográfico	Mayor precisión en zonas de alta densidad de sensores frente a zonas periféricas.	Uso de normalización de datos y validación cruzada por zonas para equilibrar el rendimiento.
Sesgo Temporal	El modelo podría sobreajustarse a un periodo específico (ej. vacaciones o pandemia).	Entrenamiento con series temporales extensas (>17 meses) para capturar la estacionalidad real.
Sesgo de Muestreo	Fallos sistemáticos en ciertos modelos de sensores de tráfico.	Limpieza exhaustiva mediante el Pipeline de Datos y eliminación de *outliers* inconsistentes.

9.3. Accesibilidad y Usabilidad

La interfaz de usuario en **Streamlit** ha sido diseñada para ser inclusiva y funcional:

- **Diseño Responsivo:** Accesible desde múltiples dispositivos (PC, tablets y smartphones) manteniendo la integridad visual.
- **Visualización Cognitiva:** Uso de paletas de colores de alto contraste y gráficos interactivos simplificados para facilitar la interpretación de datos complejos por usuarios con distintos niveles de conocimiento técnico.
- **Estandarización futura:** Se prevé la implementación de etiquetas descriptivas compatibles con lectores de pantalla (WCAG) en fases posteriores del despliegue.

9.4. Uso Ético del Sistema

SmartTrafficFlow AI se presenta estrictamente como una **herramienta de apoyo a la toma de decisiones**. No está diseñada para labores de vigilancia, control de tráfico punitivo o cualquier otra aplicación que vulnere las libertades civiles. Su objetivo es puramente educativo, técnico y de optimización de la movilidad urbana sostenible.

10. Backlog Inicial (Historias de Usuario)

El desarrollo de **SmartTrafficFlow AI** se ha desglosado en historias de usuario (HU) que cubren tanto los procesos internos del sistema como la interacción final del usuario. Estas historias guiarán el desarrollo ágil durante las próximas semanas.

ID	Historia de Usuario	Descripción (Como... quiero... para...)	Criterios de Aceptación (Definición de Hecho)
HU01	**Ingesta de Datos**	**Como sistema**, quiero cargar el *Madrid Traffic Dataset* desde archivos CSV para procesar la información de los sensores.	• Lectura correcta de archivos fuente. • Identificación y mapeo de columnas principales. • Persistencia inicial sin errores de carga.
HU02	**Limpieza y Calidad**	**Como sistema**, quiero automatizar la limpieza de datos para asegurar la fiabilidad de las predicciones.	• Gestión de valores nulos (imputación/eliminación). • Normalización de formatos y tipos de datos. • Dataset limpio disponible en el pipeline.
HU03	**Ingeniería de Atributos**	**Como sistema**, quiero generar variables temporales y climáticas para mejorar el aprendizaje del modelo.	• Extracción de hora, día y festivos del timestamp. • Integración de variables meteorológicas. • Almacenamiento del set de entrenamiento final.
HU04	**Entrenamiento ML**	**Como sistema**, quiero entrenar modelos de regresión (XGBoost/Random Forest) para predecir niveles de tráfico.	• Entrenamiento exitoso con los datos procesados. • Exportación del modelo entrenado (ej. formato .pkl). • Tiempos de ejecución dentro de márgenes aceptables.
HU05	**Evaluación Técnica**	**Como sistema**, quiero calcular métricas de error (MAE/RMSE) para validar la precisión del modelo.	• Cálculo automático de métricas tras el test. • Generación de reportes de rendimiento técnico. • Comparativa de precisión contra un baseline.
HU06	**Inferencia Predictiva**	**Como sistema**, quiero generar predicciones a t+30 y t+60 para anticipar la congestión futura.	• Generación de valores numéricos de predicción. • Formato de salida compatible con el Dashboard. • Almacenamiento seguro de los resultados generados.
HU07	**Visualización Histórica**	**Como usuario**, quiero consultar gráficos de evolución	• Representación visual fluida en el navegador.

ID	Historia de Usuario	Descripción (Como... quiero... para...)	Criterios de Aceptación (Definición de Hecho)
		histórica para identificar patrones de tráfico pasados.	• Gráficos temporales interactivos y claros. • Integridad de la información mostrada.
HU08	**Panel de Predicción**	**Como usuario**, quiero visualizar las estimaciones futuras para planificar mis desplazamientos.	• Visualización diferenciada entre dato real y predicho. • Interfaz clara e intuitiva en Streamlit. • Tiempo de respuesta del dashboard inferior a 2s.
HU09	**Filtrado Geográfico**	**Como usuario**, quiero seleccionar sensores o zonas específicas para obtener información localizada.	• Selector dinámico de sensores funcional. • Actualización automática de gráficos al filtrar. • Identificación visual unívoca de cada sensor.
HU10	**Acceso Web (UX)**	**Como usuario**, quiero acceder a un dashboard web integrado para gestionar toda la información en un solo lugar.	• Despliegue funcional de la aplicación web. • Interfaz responsive (compatible con varios dispositivos). • Navegación sencilla sin errores de carga.

11. Plan de Trabajo (6 Semanas)

El proyecto **SmartTrafficFlow AI** se ejecutará en un ciclo de **6 semanas**, siguiendo una metodología ágil e incremental. El desarrollo se divide en fases críticas donde cada etapa es requisito indispensable para la siguiente (*pipeline* de dependencias).

11.1. Cronograma y Reparto de Responsabilidades

Semana	Fase de Desarrollo	Actividades Clave	Responsables
S1	**Infraestructura**	Configuración del repositorio, entorno virtual e ingesta del dataset.	Donovan, Marcos
S2	**EDA y Calidad**	Limpieza de datos y Análisis Exploratorio (EDA) para identificar patrones.	Donovan, Jokin
S3	**Preprocesamiento**	*Feature engineering* y generación de sets de entrenamiento/test.	Donovan, Francisco
S4	**Modelado (Hito)**	Entrenamiento de algoritmos (XGBoost/RF) y ajuste de parámetros.	Francisco, Jokin

Semana	Fase de Desarrollo	Actividades Clave	Responsables
S5	**Visualización**	Desarrollo del dashboard interactivo y conexión con el modelo.	Marcos, Donovan
S6	**Cierre y Entrega**	Pruebas de integración, documentación técnica y despliegue final.	Todo el equipo

11.2. Hitos Principales y Dependencias

Para asegurar el éxito de la entrega, se han establecido los siguientes puntos de control:

1. **Hito 1 (S2):** *Data Readiness*. El dataset está limpio y validado estadísticamente.
2. **Hito 2 (S4 - Crítico):** *Model Validation*. Disponibilidad de un modelo funcional con métricas de error aceptables.
3. **Hito 3 (S5):** *Dashboard MVP*. Interfaz web capaz de consumir y mostrar predicciones.
4. **Hito 4 (S6):** *Final Release*. Entrega del repositorio completo y documentación técnica.

Dependencia Crítica: El flujo sigue una ruta crítica: **Datos → Modelo → Dashboard**. No se iniciará el desarrollo del dashboard de predicción hasta que el modelo alcance una precisión mínima validada en la semana 4.

11.3. Gestión de Riesgos Iniciales

Se han identificado riesgos técnicos con sus respectivos planes de contingencia para evitar desviaciones en el cronograma:

- **Volumen de Datos (R1):** Si el procesamiento es lento, se trabajará con un *subset* optimizado de sensores críticos de la M-30.
- **Precisión Insuficiente (R2):** Si el error (MAE) es alto, se pivotará hacia modelos más complejos (XGBoost) o se ampliará el *feature engineering*.
- **Integración Frontend-ML (R3):** Para evitar retrasos, se utilizará **Streamlit** por su compatibilidad nativa con Python, eliminando la necesidad de una API compleja.

12. Estrategia de Desarrollo

El éxito técnico de **SmartTrafficFlow AI** se basa en un ciclo de vida de desarrollo de software (SDLC) riguroso, utilizando metodologías ágiles y control de versiones profesional.

12.1. Flujo de Trabajo (Git Flow)

Se implementará un modelo de ramificación ramificado para garantizar que la versión de producción sea siempre estable:

- **`main`**: Rama protegida que contiene únicamente código verificado y listo para entrega.
- **`develop`**: Eje central de integración donde se consolidan las funcionalidades finalizadas.
- **`feature/*`**: Ramas temporales para tareas específicas (ej. `feature/limpieza-datos`, `feature/entrenamiento-xgb`). Al finalizar, se integran en *develop* mediante *Pull Requests*.

12.2. Protocolo de Validación y Testing

Para asegurar la calidad del sistema, se aplicará una estrategia de pruebas en tres niveles:

1. **Validación de Datos:** Chequeos automáticos de integridad tras el proceso de limpieza (verificación de tipos y ausencia de nulos).
2. **Evaluación de Modelos:** Auditoría continua de métricas **MAE y RMSE** comparadas con un modelo base (*baseline*).
3. Testing de Integración: Pruebas de flujo completo para asegurar que el Dashboard en Streamlit visualiza correctamente los *outputs* del motor de ML.

13. Matriz de Riesgos Técnicos Actualizada

Hemos identificado y priorizado los riesgos que podrían comprometer los hitos del proyecto, estableciendo planes de contingencia inmediatos.

ID	Riesgo Técnico	Impacto	Probabilidad	Plan de Mitigación
R1	**Baja Calidad del Dato**	Crítico	Alta	Implementación de técnicas de imputación estadística y filtrado de *outliers* en el Pipeline.
R2	**Infraajuste del Modelo**	Alto	Media	Evaluación de algoritmos de gradiente (*XGBoost*) y optimización de hiperparámetros.
R3	**Conflictos de Entorno**	Medio	Media	Uso estricto de entornos virtuales (`venv`) y archivo de dependencias `requirements.txt`.
R4	**Latencia en Inferencia**	Medio	Baja	Pre-computación de predicciones para los sensores más críticos y optimización de consultas.

14. Estructura del Repositorio

El repositorio en GitHub ha sido organizado siguiendo los estándares de la industria para proyectos de Ciencia de Datos e Ingeniería.

URL del Proyecto: `https://github.com/fpeirop/PROYECTO-IA-BIGDATA.git`

14.1. Organización de Directorios

- **`docs/`**: Documentación técnica, diagramas de arquitectura y manuales de usuario.
- **`src/`**: Código fuente segmentado en módulos (`data_processing/`, `models/`, `dashboard/`).
- **`data/`**: Almacenamiento local del dataset (bruto y procesado).
- **`environment/`**: Configuración del entorno de ejecución y dependencias.
- **`README.md`**: Documento principal con instrucciones de instalación, ejecución y descripción del equipo.